

외삽(Extrapolation)

완전 정복 학습 노트

기초 이론 · OOD 일반화 · 신경망 외삽 방법론

논문 기반 심화 학습 자료 | Kookmin Univ. IE Lab

2026. 07. 06

목차

Chapter 1 외삽이란 무엇인가 — 기초 이론과 수학적 정의

- 1.1 보간 vs 외삽 개념 정의
- 1.2 통계적 외삽의 한계
- 1.3 Richardson 외삽법
- 1.4 외삽 불확실성 측정

Chapter 2 OOD 일반화 — 분포 이동과 도메인 일반화

- 2.1 i.i.d. 가정의 붕괴
- 2.2 Covariate Shift / Dataset Shift
- 2.3 Invariant Risk Minimization (IRM)
- 2.4 DomainBed 벤치마크 정리
- 2.5 인과 관점의 OOD

Chapter 3 신경망 외삽 방법론 — 딥러닝에서 어떻게 외삽하는가

- 3.1 신경망은 왜 외삽에 실패하는가
- 3.2 수치 연산 특화: EQL / NALU
- 3.3 단조 제약 신경망
- 3.4 PINN — 물리법칙 내재화
- 3.5 Implicit 모델의 외삽 능력
- 3.6 방법론 비교 정리

Chapter 4 연구 동향 요약 및 핵심 논문 가이드

- 4.1 분야별 대표 논문 정리
- 4.2 연구 흐름 타임라인
- 4.3 나의 연구에 적용하기

Chapter 1

외삽이란 무엇인가

기초 이론 · 수학적 정의 · 통계적 한계

1.1 보간(Interpolation) vs 외삽(Extrapolation)

머신러닝·통계 모델이 '잘 동작한다'는 것은 대부분 훈련 분포 내(in-distribution)에서 잘 동작한다는 의미다. 이때 훈련 데이터 범위 안에서 값을 추정하는 것이 보간, 범위 밖에서 추정하는 것이 외삽이다.

구분	보간 (Interpolation)	외삽 (Extrapolation)
추정 위치	훈련 데이터 범위 내부	훈련 데이터 범위 외부
신뢰도	일반적으로 높음	모델·조건에 따라 매우 낮음
오차 특성	경계 조건 내 오차 제어 가능	오차가 거리에 따라 급격히 증가
대표 방법	선형 보간, Spline, GP 보간	선형 외삽, ARIMA 예측, RUL 예측
ML에서의 예시	같은 분포 테스트셋 평가	OOD 일반화, 미래 예측, RUL

[!] 핵심: 모든 예측 모델은 '어디서 데이터를 봤는가'에 의해 제한된다. 외삽이란 그 경계 밖으로 나가는 것이고, 이 경계를 '지지 집합(support)'이라 부른다.

1.2 수학적 정의 — 지지 집합과 외삽 영역

데이터셋 $D = \{(x_i, y_i)\}$ 로 학습된 함수 $f: X \rightarrow Y$ 가 있을 때, 훈련 입력의 볼록 껍질(convex hull) $C(X_{\text{train}})$ 을 지지 집합으로 정의한다.

$$\begin{aligned} x_{\text{new}} \in C(X_{\text{train}}) &\rightarrow \text{보간} \\ x_{\text{new}} \notin C(X_{\text{train}}) &\rightarrow \text{외삽} \end{aligned}$$

고차원에서는 거의 모든 테스트 포인트가 외삽 영역에 속하게 된다 (Curse of Dimensionality). 이것이 Bartley et al. (2019)가 지적한 핵심 문제다: 차원이 커질수록 외삽 위험은 피할 수 없다.

1.3 Richardson 외삽법 — 수치 해석적 접근

수치해석에서는 단계 크기 h 를 줄여가며 수렴값을 추정하는 Richardson 외삽법이 오래전부터 사용됐다. 최근 Teckentrup et al. (2024)은 이를 확률론적(Probabilistic)으로 확장했다.

Richardson 외삽의 아이디어

계산값 $A(h) = A^* + c \cdot h^p + O(h^{(p+1)})$ 일 때, 두 단계 크기 h_1, h_2 에서의 계산값으로 A^* 를 추정: $A^* \approx (h_2^p \cdot A(h_1) - h_1^p \cdot A(h_2)) / (h_2^p - h_1^p)$

Probabilistic Richardson Extrapolation은 이 추정에 Gaussian Process prior를 얹어 불확실성까지 정량화한다. 이는 Chapter 3의 Bayesian 외삽과 연결된다.

1.4 외삽 불확실성 — 왜 오차가 폭발하는가

외삽 오차가 훈련 범위 밖에서 급증하는 이유를 직관적으로 이해하려면 분산-편향 트레이드오프(bias-variance tradeoff)를 외삽 맥락에 적용해야 한다.

오차 요인	보간 영역	외삽 영역
편향 (Bias)	모델 복잡도로 제어 가능	모델 구조 가정이 틀리면 선형 증가
분산 (Variance)	데이터 밀도에 비례	데이터 없음 → 최대 분산
모델 불확실성	에피스테믹 UQ로 측정	신뢰구간이 의미없이 발산
대책	교차검증(CV)으로 확인	물리 제약, 사전 지식 주입 필요

[!] 핵심 교훈: 외삽에서 '모델이 얼마나 틀릴 수 있는지'를 아는 것이 예측값 자체만큼 중요하다. 불확실성 정량화(UQ)는 외삽의 핵심 도구다.

Chapter 2

OOD 일반화

분포 이동 · 도메인 일반화 · 인과적 접근

2.1 i.i.d. 가정의 붕괴

표준 머신러닝은 훈련 데이터와 테스트 데이터가 동일한 분포에서 독립적으로 추출된다는 i.i.d. (independent and identically distributed) 가정에 의존한다. 그러나 실세계에서 이 가정은 자주 붕괴된다.

분포 이동 유형	정의	예시
Covariate Shift	$P(X)$ 가 바뀌지만 $P(Y X)$ 는 동일	다른 병원 장비로 찍은 의료 영상
Label Shift	$P(Y)$ 가 바뀌지만 $P(X Y)$ 는 동일	클래스 비율이 다른 배포 환경
Concept Drift	$P(Y X)$ 자체가 시간에 따라 변화	주식 가격 패턴의 시계열 변화
Domain Shift	전체 생성 과정이 다른 도메인	합성 데이터 → 실제 데이터 전이
Covariate+Label	$P(X)$ 와 $P(Y)$ 모두 변화 (일반 OOD)	다양한 환경 변화 동시 발생

2.2 OOD 일반화의 공식 정의

Ye et al. (2021) 의 이론적 프레임워크에 따르면, OOD 일반화 문제는 다음과 같이 정의된다:

OOD 일반화 목표

훈련 환경 집합 $E_{\text{train}} = \{e_1, e_2, \dots\}$ 에서 학습하여, 미지의 테스트 환경 e_{test} (not in E_{train}) 에서도 낮은 리스크를 달성하는 가설 h 를 찾아라. $\min_h \max_{e \in E_{\text{all}}} R^e(h)$

이것이 표준 ERM(Empirical Risk Minimization)과 다른 점: ERM은 훈련 분포의 평균 리스크를 최소화하지만, OOD 목표는 최악의 환경에서의 리스크를 최소화한다.

2.3 Invariant Risk Minimization (IRM)

Arjovsky et al. (2019, 2021) 의 IRM은 OOD 일반화의 대표 알고리즘이다. 핵심 아이디어: 모든 환경에서 동시에 최적인 선형 분류기를 유도하는 표현(representation) Φ 를 학습한다.

IRM 목적함수

$\min_{\{\Phi, w\}} \sum_e R^e(w * \Phi)$ s.t. $w \in \operatorname{argmin}_{\{w\}} R^e(w * \Phi)$ for all e 직관: 환경마다 따로 fine-tune할 필요 없이 동일한 w 로 모든 환경에서 최적이어야 함

실용적으로는 이 bi-level 최적화를 penalized 형태로 완화된 IRMv1을 사용한다:

$$L_{\text{IRMv1}} = \mathbb{E} [R^e() + \lambda * \|\text{grad}_{\{w=1\}} R^e(w)\|^2]$$

2.4 DomainBed 벤치마크 — IRM의 진실

Gulrajani & Lopez-Paz (2020)의 DomainBed는 충격적인 결과를 보였다: 적절한 하이퍼파라미터 탐색과 model selection 하에서 단순 ERM이 IRM 및 대부분의 OOD 알고리즘보다 낮거나 동등하다는 것.

[!] DomainBed 교훈: OOD 알고리즘의 성능 향상은 알고리즘 자체보다 하이퍼파라미터 튜닝과 모델 선택 전략에 의해 결정되는 경우가 많다. '새로운 방법'이라는 주장은 공정한 비교에서 검증해야 한다.

2.5 인과(Causal) 관점의 OOD

OOD 일반화를 인과 그래프로 바라보면 근본적인 해결책을 찾을 수 있다. Sheth et al. (2022)의 인과 관점 정리:

관점	핵심 아이디어	OOD 해결책
통계적	입출력의 상관관계 최대화	더 많은 데이터, 정규화
불변성(IRM)	환경 불변 특징 찾기	IRM, CORAL, GroupDRO
인과적	진짜 원인 변수 찾기	Structural Causal Model(SCM)
메타러닝	적응 능력 학습	MAML, few-shot adaptation

2.6 시계열 OOD — 특수성

Wu et al. (2025)의 시계열 OOD 서베이에 따르면, 시계열 데이터는 정상적인 OOD와 다른 두 가지 특수한 분포 이동을 가진다:

- ① 시간적 분포 이동: 분포가 시간축을 따라 연속적으로 변화 (Concept Drift)
- ② 주기적 분포 이동: 계절성·주기에 의한 반복적 분포 변화

배터리 RUL 예측은 이 두 유형이 모두 적용되는 전형적인 사례다: 사용 패턴에 따라 분포가 연속적으로 변하고, 충방전 사이클이 주기적 구조를 만든다.

Chapter 3

신경망 외삽 방법론

왜 실패하는가 · 어떻게 해결하는가 · 방법론 비교

3.1 신경망은 왜 외삽에 실패하는가

Xu et al. (2021)의 「How Neural Networks Extrapolate」는 이 질문에 가장 체계적인 답을 제시한 논문이다. 핵심 발견:

- ① ReLU 네트워크는 훈련 범위 밖에서 선형(affine)으로 동작한다
→ 입력이 훈련 범위를 벗어나면 마지막 활성화된 선형 구간이 그대로 연장됨
- ② Tanh, Sigmoid 네트워크는 상수값으로 수렴한다
→ 포화(saturation)로 인해 경계 밖에서는 항상 같은 값을 예측
- ③ 훈련 범위 근방에서만 외삽 신호를 학습할 수 있다
→ '경계 근처 보간'이 '진짜 외삽'보다 쉽다

활성화 함수	외삽 범위 밖 거동	함의
ReLU	선형(마지막 활성 구간 연장)	방향은 맞지만 곡률 없음
Tanh/Sigmoid	상수로 포화	분류엔 무해, 회귀엔 치명적
Sin (Siren)	주기적 반복	물리 해석 가능, 과적합 위험
ELU/GELU	좌측 -1에 포화, 우측 선형	ReLU보다 약간 나음

3.2 수치 외삽 특화 아키텍처

EQL — Equation Learner (Martius & Lampert, 2016)

수식 자체를 학습하는 아키텍처. 뉴런의 활성화 함수를 {sin, cos, ×, ÷, id, a} 등 수학 기본 연산으로 구성하여, 학습 결과가 해석 가능한 수식이 되도록 한다.

EQL의 외삽 우수성 이유

$f(x) = \sin(x)$ 를 학습시키면 실제로 sin 뉴런이 활성화되어, 훈련 범위 밖에서도 수학적으로 정확한 sin 함수를 외삽한다. 반면 일반 MLP는 sin을 근사하는 조각별 선형 함수를 학습해 범위 밖에서 발산한다.

NALU — Neural Arithmetic Logic Units (Trask et al., 2018)

덧셈·뺄셈·곱셈·나눗셈 등 수치 연산을 학습할 수 있는 특수 뉴런 모듈. 기존 신경망이 계수 카운팅, 누적합 같은 체계적 수치 연산에서 외삽이 실패하는 문제를 해결한다.

NAC (Neural Accumulator): $W = \tanh(\hat{W}) \cdot (M) \rightarrow \cdot$

NALU: $g \cdot \text{NAC}(x) + (1-g) \cdot \exp(\text{NAC}(\log|x|)) \rightarrow \cdot$

3.3 단조 제약 신경망 (Monotonic Neural Networks)

많은 공학 문제에서 입출력 관계에 단조성(monotonicity) 제약이 존재한다. 예: 배터리 충전량이 많을수록 전압은 높아진다. 이 제약을 강제하면 외삽이 안정된다.

방법	접근법	장점	단점
Weight Clipping	가중치를 비음수로 제한	간단한 구현	표현력 제한
Certified MNN (Liu, 2022)	리아푸노프 증명 기반	수학적 보장	학습 복잡
CMNN (Runje, 2023)	단조 활성화 + 구조적 제약	높은 표현력 + 보장	추가 설계 필요
Min-Max 구조	Min/Max 레이어 교차 배치	직관적	깊이 제한

[!] 배터리 연구 적용 포인트: SOC(State of Charge)에 따른 OCV(Open Circuit Voltage) 관계는 단조 증가 제약을 가진다. CMNN으로 이 관계를 학습하면 훈련 범위 밖 SOC에서도 물리적으로 타당한 외삽이 가능하다.

3.4 Physics-Informed Neural Networks (PINN)

Raissi et al. (2019)에서 제안된 PINN은 손실함수에 물리 법칙(PDE 잔차)을 직접 내재화하여, 데이터 범위 밖에서도 물리적으로 일관된 예측을 만들어낸다.

$$L_{\text{PINN}} = L_{\text{data}} + \lambda * L_{\text{physics}}$$

$$L_{\text{physics}} = \|N[u](x,t)\|^2 \text{ where } N[\cdot] \text{ is the PDE operator}$$

PINN의 외삽 실패 원인 (Fessler et al., 2023)

그러나 PINN도 외삽에서 실패할 수 있다. 주요 원인:

- ① Spectral bias: 저주파 성분을 먼저 학습, 고주파 성분 외삽 실패
- ② 도메인 경계 부근 손실 가중치 불균형
- ③ 훈련 포인트 분포가 외삽 방향으로 희박

DeepONet 기반 신뢰 가능한 외삽 (Zhu et al., 2022)

Operator learning 프레임워크인 DeepONet에 불확실성 정량화를 결합해, 외삽 영역에서의 신뢰구간을 제공하는 방법. 외삽 신뢰도가 낮을 때 경고를 발생시킨다.

3.5 Implicit 모델과 Transductive 외삽

Decugis et al. (2024)은 implicit 신경망(고정점 방정식의 해로 출력을 정의하는 모델)이 explicit 네트워크보다 외삽 능력이 우수함을 증명했다.

Netanyahu et al. (2023)의 Transductive 외삽은 테스트 포인트 자체를 학습 과정에 포함시켜 '이 특정 포인트로의 외삽'에 특화된 모델을 만드는 접근법이다.

3.6 방법론 종합 비교

방법론	외삽 원리	데이터 요구	해석 가능성	공학 적용
표준 MLP	경험적 근사	대량 필요	낮음	기준선
EQL	수식 발견	적음	매우 높음	물리 관계
NALU	수치 연산 학습	중간	중간	카운팅, 누적
Monotonic NN	물리 제약 주입	중간	높음	SOC-OCV, 열화
PINN	PDE 내재화	매우 적음	높음	전기화학 모델
DeepONet	연산자 학습 + UQ	많음	중간	다물리 시스템
IRM (OOD)	불변 특징 학습	다환경 필요	낮음	도메인 이동

Chapter 4

연구 동향 & 핵심 논문 가이드

타임라인 · 분야별 대표 논문 · 나의 연구에 적용하기

4.1 연구 흐름 타임라인 (~30년)

시기	핵심 발전	대표 논문/방법
1990s	통계적 외삽 이론 정립 · Vapnik SVM · VC dimension	Vapnik (1995) Statistical Learning Theory
2000s	커널 방법 · Gaussian Process · Covariate Shift 개념 정립	Rasmussen & Williams (2006) GP Shimodaira (2000) Covariate Shift
2010–15	딥러닝 부상 · 수식 학습 신경망 등장	Martius & Lampert (2016) EQL Goodfellow et al. (2014) GAN
2016–19	OOD 문제 공식화 · NALU · IRM 등장	Trask et al. (2018) NALU Arjovsky et al. (2019) IRM
2020–21	PINN · DomainBed · 대규모 OOD 벤치마크	Raissi et al. (2019) PINN Gulrajani (2020) DomainBed Xu et al. (2021) How NNs Extrapolate
2022–23	Monotonic NN · DeepONet UQ · Causal OOD · 배터리 ML	Runje (2023) CMNN Zhu (2022) DeepONet+UQ Fessler (2023) PINN 외삽 실패 분석
2024–25	Implicit 모델 · Probabilistic 외삽 · 시계열 OOD 서베이	Decugis (2024) Implicit 모델 Teckentrup (2024) Prob. Richardson Wu (2025) 시계열 OOD 서베이

4.2 분야별 필독 논문 — 우선순위 가이드

★★★★ 반드시 읽어야 할 논문

Xu et al. (2021)	How Neural Networks Extrapolate: From Feedforward to GNN	PDF	신경망 외삽 실패 원인의 바이블
Gulrajani & Lopez-Paz (2020)	In Search of Lost Domain Generalization	PDF	DomainBed: OOD 알고리즘 공정 비교

Liu et al. (2023)	Towards OOD Generalization: A Survey	PDF	OOD 전체 서베이, 입문 필독
-------------------	--------------------------------------	-----	-------------------

★★☆ 방법론 심화

Trask et al. (2018)	Neural Arithmetic Logic Units	PDF	수치 외삽 특화 아키텍처
Runje & Shankaranarayana (2023)	Constrained Monotonic Neural Networks	PDF	단조 제약 최신 방법
Fesser et al. (2023)	Extrapolation Failures in PINNs	PDF	PINN 외삽 실패 원인 분석
Teckentrup et al. (2024)	Probabilistic Richardson Extrapolation	PDF	Bayesian+수치해석 융합

★☆☆ 배터리 응용

Aykol et al. (2021)	Physics + ML for Battery Lifetime	PDF	배터리 수명 예측 물리-ML 융합 로드맵
Li et al. (2023)	Predicting Battery Lifetime Under Varying Usage	PDF	OOD 외삽 포함 RUL 예측

4.3 나의 연구에 적용하기 — 배터리 외삽

배터리 함침 공정 최적화·RUL 예측 연구에 외삽 방법론을 적용할 때의 로드맵:

연구 문제	추천 방법론	참고 논문
SOC-OCV 곡선 외삽 (측정 불가 범위 추정)	Monotonic NN (CMNN) + 물리 제약	Runje (2023) Aykol (2021)
다양한 충방전 조건에서의 RUL 예측 (OOD)	IRM 또는 GroupDRO + 도메인 일반화	Liu (2023) Gulrajani (2020)
EIS 스펙트럼 기반 시간 외삽	PINN + 등가회로 모델 물리 법칙 내재화	Fesser (2023) Zhu (2022)
제한 데이터에서의 열화 예측	EQL (수식 학습) + Bayesian UQ	Martius (2016) Teckentrup (2024)

[!] 최종 조언: 외삽 문제를 풀 때 가장 먼저 할 일은 '어떤 물리적/수학적 불변성이 존재하는가'를 명확히 하는 것이다. 단조성, PDE 제약, 보존 법칙 등 도메인 지식이 있다면 그것이 최고의 외삽 도구가 된다.

본 자료는 Perplexity Computer가 생성한 학습용 문서입니다. 수록된 논문은 `literec_study` GitHub 레포지토리의 `extrapolation-papers` 폴더에서 PDF로 확인할 수 있습니다. github.com/amumujs-create/literec_study