

논문 기반 세미나 · 50분

외삽 (Extrapolation) 훈련 범위 밖 예측 — 정의 · 실패 원인 · 대응법 · 성능 검증

1부 외삽 정의 · 2부 실패 원인 · 3부 대응법 + 성능 검증

발표 구조 — 외삽 정의 · 실패 원인 · 대응법 · 성능 검증

Q1 외삽 정의

보간 vs 외삽 · convex hull

Q2 실패 원인

식별불가 · hull 밖 · epistemic · ReLU

Q3 대응·검증

대응법(가정) · 성능 검증

1부 외삽 정의 (5분)

- 보간 vs 외삽 — 새 입력이 범위 안/밖인지
- 훈련 범위 = convex hull
- 내부 적합도 ≠ 외삽 성능
- 논문: Bartley 2019

2부 실패 원인 (15분)

- ① 데이터만으론 못 고름 — Pfister 2024
- ② 훈련 범위 밖이 기본 — Bartley 2019
- ③ 밖에선 불확실성↑ — Ghahramani
- ④ ReLU→직선 — Xu 2021


3부 대응법·성능 검증 (27분)

- 대응법 — 가정 넣기: EQL / CMNN / PINN
- 모를 때 — 불확실성(UQ) · 예측 안 함(기권) (Zhu)
- 성능 검증 — 범위 확인 · OoD-Bench · DomainBed

외삽 정의 → 실패 원인 → 대응법 + 성능 검증

핵심: 밖 예측을 정당화하는 건 데이터가 아니라 가정

가정(Assumption) — 오늘 발표의 중심 개념



① 가정이란?

- 훈련 범위 밖에서 함수가
- 어떻게 거동할지에 대한
- 사전 제약·구조적 지식

② 왜 필요한가

- 데이터만으로는 밖을 유일하게
- 정할 수 없음 (Pfister 2024)
- → 가정 없이는 외삽 불가

④ 그림 해석

- 훈련점(●)은 세 곡선 공통 · $x > 2$ 밖: A선형·B지수·C비선형 → 예측 전부 다름
- 데이터는 같고 가정만 다름 = 오늘 발표 출발점

③ 어디에 넣나

- 활성화 ϕ → 함수족 가정
- 단조·PDE·UQ/기권 → 방향·물리·유보
- 3부 방법과 1:1 대응

가정 = 밖에서의 함수 거동을 미리 제약하는 사전 지식

같은 훈련 데이터, 다른 가정 → 다른 외삽

1부 · 외삽이란 무엇인가

훈련 범위의 안과 밖 — 오늘 내내 쓸 좌표계

1

보간 vs 외삽: 입력이 훈련 범위 안/
밖인지

2


훈련 범위의 정확한 정의 = convex
hull

3


대표 사례: 내부 적합과 외부 발산

외삽 = 훈련 범위(hull) 밖에서의 예측

Interpolation



Extrapolation



판별 기준

- 입력 x 가 훈련 범위 안 $\rightarrow$ 보간
- 입력 x 가 훈련 범위 밖 $\rightarrow$ 외삽
- 같은 모델도 입력마다
- 보간·외삽 동시 가능
- 먼저 확인: '이 입력, 범위 밖?'
- 피할 말: '모델이 외삽?' (입력 기준)

적용 예

- 키 160~180cm로 학습 $\rightarrow$ 175cm 예측 = 보간 (안전)
- 같은 모델에 195cm 예측 = 외삽 (본 적 없음)
- 여름 데이터로 학습한 전력수요 모델 $\rightarrow$ 겨울 예측 = 외삽 (시간축도 마찬가지)


그림·기호 약속

- 음영 = 훈련 범위 (hull)
- 음영 밖 = 외삽 구간
- 이후 모든 장표에서 동일 좌표계
- 논문: Bartley 2019 (훈련 범위 정의)

입력이 훈련 범위 안 $\rightarrow$ 보간, 밖 $\rightarrow$ 외삽

같은 모델도 **입력이 범위 안/밖**에 따라 달라짐

'훈련 범위'를 수학적으로 — convex hull



예시 — 조합의 함정

- 20~30°C·습도 40~60%로 학습 → (35°C, 50%) 예측 = 밖
- 함정: (22도, 59%)처럼 '변수별로는 범위 안'이어도 조합이 훈련 범위 밖일 수 있다

convex hull — ① 개념 · ② 수식


- ① 개념 — 훈련 row(●)들을 고무줄로 감싼 영역
(외곽 끝 + 그 안 전체, 피쳐 하나씩 아님)
- ② 수식 — $\text{Conv}(X_{\text{train}}) = \{x = \sum \alpha_i x_i \mid x_i = \text{row}(\text{모든 컬럼}), \alpha_i \geq 0, \sum \alpha_i = 1\}$

③ 의미 · ④ 왜 정의?

- hull 안 ($x \in$) → 보간 — 훈련점 섞기로 만들 수 있음
- hull 밖 ($x \notin$) → 외삽 — 본 적 없는 입력·조합
- $\sum=1$ → 섞는 비율 100%, 고무줄 안 · $\sum \neq 1$ → 밖
- ④ 왜 정의? — '범위 밖'을 느낌 → 수학 판정
- min/max·감각 대신 공식 기준 → 3부 검증 가능

훈련 범위 = convex hull — 안이면 보간, 밖이면 외삽
느낌이 아니라 판정 가능한 기준 (3부 검증의 토대)

훈련구간 적합도는 외삽 성능을 보증하지 않는다



예시 — 숫자로

- 설비 열화 곡선 100일치에 고차 다항식 적합: 훈련 오차 0.1% (완벽해 보임)
- 130일째 예측: 물리적으로 불가능한 음수 출력 — 안의 성적표는 밖을 모른다

관찰

- 4차 다항식 · 훈련구간 오차 ≈ 0
- 경계를 넘는 즉시 발산
- 차수 높일수록 안은 더 잘 맞고
- 밖은 더 크게 터진다

여기서 고정할 교훈

- '안에서 잘 맞는다'와
- '밖에서 맞는다'는 다른 질문
- → 왜 다른가? 2부에서 해부

훈련구간 오차 ≈ 0 이어도 경계 밖에서 즉시 발산

안의 성적은 밖을 보증하지 않는다 — 이유는 2부에서

2부 · 외삽 실패 원인 (4)

훈련 범위 밖에서 예측이 깨지는 이유

1

이유 1·2: 데이터가 함수를 못 정하고, 고차원에선 거의 전부가 밖

2

이유 3: 범위 밖에선 '모름'(불확실성)이 커진다

3

이유 4: 신경망도 밖에서는 직선이 된다

데이터가 함수를 정해 주지 않는다



예시 — 배터리 수명

- 100사이클까지의 용량 데이터: '선형 열화'와 '지수 열화' 둘 다 완벽 적합
- 500사이클 수명 예측은 두 가설이 2배 차이 — 데이터는 어느 쪽인지 말해주지 않는다

같은 점, 다른 함수

- 훈련점을 지나는 함수(가설)는 무한히 많다
- 그림 — 직선·지수: 훈련 구간(OBSERVED) 안
- 예서는 둘 다 • 통과 → 구분 불가
- 밖(UNIDENTIFIED)으로 가면 전부 갈라진다
- 데이터를 더 모아도 (안에서만 늘면)
- 구별 불가능은 그대로 (Pfister 2024)



핵심 결론 (s03과 연결)

- 밖을 지탱하는 것은
- 데이터가 아니라 가정이다
- 가정 = 밖 거동에 대한 사전 제약
- → 어느 함수쪽을 믿을지 선택해야 함

훈련 구간 안에서는 맞춰지지만, 밖에서 갈라진다 — 데이터로는 못 고른다

밖을 지탱하는 것은 데이터가 아니라 가정이다 (핵심 문장)

고차원에선 새 데이터가 거의 전부 범위 밖



차원의 저주 (Bartley 2019)

- 2차원(왼쪽): 범위가 커 보인다
- 차원 $\uparrow$ $\rightarrow$ 새 입력이 훈련 범위 안에 있을 확률이 지수적으로 0으로 (오른쪽 곡선)
- 이미지·다채널 센서 = 이미 고차원

예시 — 센서 20채널이면



- 각 채널이 훈련 범위 안에 있을 확률 95%라 해도, 20채널 '조합'이 전부 안일 확률 $\approx 0.95^{20} \approx 36\%$
- 실제 훈련 범위는 축 정렬 상자보다 훨씬 좁다 $\rightarrow$ 조합 기준으로는 대부분이 이미 밖
- 이미지(수만 차원)·다변량 시계열 — 여러분이 다루는 데이터가 정확히 이 영역

함의

- '우리 테스트는 안이겠지' 근거 없음
- 외삽은 예외가 아니라 기본값
- $\rightarrow$ 특수한 예외가 아니라 일반적 상황

차원 $\uparrow \Rightarrow$ 훈련 범위 안 확률 $\rightarrow 0$ — 고차원 테스트는 대부분 이미 외삽
외삽은 예외가 아니라 기본값이다

범위 밖에선 '모름'(불확실성)이 커진다



왜 세 가지로 쪼개 보나?

- 오차 원인이 다름 → 고치는 방법도 다름
- 잡음(Noise): 측정·센서·환경 — 본질적 랜덤
- → 과녁: 손 떨림 · 어디서나 비슷 · 못 줄임
- 편향(Bias): 모델 가정·구조가 틀림 — 체계적 오차
- → 과녁: 조준 틀림 · 가정·모델 바꾸면 줄임
- 모름(Var/epistemic): 데이터 없어 예측이 흔들림
- → 과녁: 위치 모름 · 그 구간 데이터 있으면 줄임

그림 읽기

- 음영 = 훈련 범위 · 안: total error 작음
- (a) 세 색 쌓임 = (b) 펼친 곡선 (같은 분해)
- 밖으로 갈수록 주황(모름·Variance)이 total을 끌어올림
- 회색(잡음)은 어디서나 비슷 · 파랑(편향)은 완만


범위 밖 · 분해 목적

- 훈련 범위 밖 = 정의상 데이터 없음
- → '모름'만 구조적으로 커짐 (그림 주황 폭발)
- → 잡음·편향만으로는 설명 안 됨
- 분해하는 이유: 어디서·왜 틀리는지 진단
- (가정 문제? 데이터 부족? 측정 한계?)
- → 3부 UQ: '모름'을 신호로 쓰기


훈련 범위 밖 — '모름'(epistemic)이 커짐 · 데이터로는 못 줄임

이 약점을 신호로 활용하는 방법이 3부 끝(UQ)에 나온다

ReLU NN — 밖에서는 직선 (Xu 2021)

Fig.1 읽기 — ϕ = 활성화 함수 (activation)

- 파란 = 훈련 구간(안) · 바깥 격자 = ReLU MLP 예측
- 3D 3장: 타깃만 다름 — 공통으로 밝은 평면(plane) · 2D: sin vs 직선

ReLU NN — 밖에서 직선 (Xu Thm.1) · ϕ 마다 밖 가정 다름

NN은 외삽 불능이 아니라 '직선'이라는 가정을 이미 하고 있다


Xu의 정리 1 (ReLU)

- ReLU MLP — 입력 멀어지면 방향마다 직선
- 깊이·너비 키워도 동일 (Thm.1, 증명)
- 위: 논문 Fig.1 · 아래: sin 학습 MLP 예시
- → 실무 기본(ReLU)의 밖 거동을 정식화

예시 해석 · Q 다른 활성화 ϕ ?

- ϕ = 활성화 함수 — '밖은 이 모양' 선언 (S16)
- 음영 안: 완벽 적합 · 밖: 접선 직선, 다시 안 굽음
- 재해석: NN 외삽 불능 ✗ — '밖 가정'을 이미 함
- Q: ReLU만? — tanh/sig: 밖 포화 · sin/cos: 주기(맞으면)
- GELU 등: ReLU 근사 → 직선 쪽 · ϕ 안 맞으면 10^2 – 10^3
- ϕ 만으론 부족(S09) — 맞춰도 검증·UQ · 자세히 → S16

왜 직선인가 — 3단 논법 · 2부 정리



① 뉴런 고정 (그림 a)

- ReLU 뉴런은 딱 한 번만 꺾인다
- 입력이 커지면 마지막 꺾임을 지나
- 커짐/꺼짐이 영원히 고정

② 층이 선형화

- 커짐이 고정된 네트워크는
- 그냥 행렬 곱셈의 연속
- 비선형 곱셈이 전부 사라짐

③ 직선 수렴 (그림 b)

- 고정된 직선들의 합 = 직선 하나
- 곱셈은 전부 데이터 근처에만 산다
- → 멀리서 보면 평평 (Thm.1)

2부 정리 — 질문을 바꿔라: '외삽 되나?' → '모델의 가정이 내 문제와 맞나?'

가정을 직접 골라 놓으면? → 3부

3부 · 외삽 대응법 + 성능 검증

가정 놓기(대응법) → 외삽 주장이 맞는지 확인(성능 검증)

1

대응법: 사전 지식 강도별 가정 놓기
4종

2

성능 검증: 훈련 범위 · 밖 종류 · 공
정 비교

방법 지도 — 사전 지식별 외삽 가정 넣기



① 함수족 (강)

- EQL: 수식 유닛 내장
- NALU: 산술로 가중치 제약
- 이득: 전역 유효 가능
- 대가: 가정이 틀릴 때 전역 실패

② 방향

- CMNN: 단조를 구조로 강제
- 실무 지식의 대부분 수준
- 이득: 밖에서도 방향 보장
- 대가: 구조 설계 비용

③ 물리

- PINN: $L_{\text{data}} + \lambda \cdot \text{PDE} (+\text{BC/IC})$
- 이득: 희소 데이터 보완
- 대가: 잔차≠외삽 보증
- (Fessler 2023 반례)


④ 무가정

- UQ: '모름'을 경보로
- 기권: 신뢰 낮으면 예측 안 함
- 이득: 과신 오답 방지
- 대가: 답변율 감소

지식 우선, 방법 후행 — 가용 사전 지식이 방법을 정한다

강한 가정 = 높은 이득 + 높은 위험


최소 개입의 가정 주입 — 활성화 함수를 타겟에 맞추기 (Xu Fig.5)



논문: Xu et al., How Neural Networks Extrapolate (ICLR 2021), Fig.5

실험 요지 (위: 논문 원본)

- 타겟이 주기함수 → 활성화를 cos으로
- 바꾸면 외삽이 된다
- 타겟이 tanh형 → tanh 활성화가 성공
- 짝이 틀리면 오차 100~1000배




예시 — 같은 sin 타겟

- (a) ReLU: 밖에서 직선 → 파동 놓침
- (b) cos 활성화: 밖에서도 파동 유지
- 활성화 선택 = '밖은 이 모양' 선언
- 가정에는 대가가 있다: 불일치 시 오차 수백 배


활성화와 타겟이 같은 족일 때만 외삽 성립 — 틀린 짝은 오차 수백 배

활성화 선택 = 함수 모양 가정의 선언. 가정에는 대가가 있다

함수 모양을 안다 (a) — EQL: 수식을 통째로 배우기



논문: Martius & Lampert, Extrapolation and Learning Equations (arXiv 2016), Fig.1



원리 (위: 논문 구조도)

- 뉴런 자리에 $\sin \cdot \cos$ ·곱셈 같은
- 수식 유닛을 심는다
- 학습이 끝나면 네트워크 자체가
- 하나의 닫힌 수식: $\hat{y} \approx \sin(1.01x)$
- 배운 식이 참 식과 같은 족이면
- → 훈련 구간 아닌 전 영역에서 유효


예시 + 대가

- 초록(EQL): 식이라서 멀리서도 파동 유지
- 주황(MLP): 같은 데이터인데 직선
- 대가: 유닛 목록 밖 함수 표현 불가 ·
- 희소화 조절 까다로움 · 고차원 취약

배운 식이 참 식과 같은 족이면 전 영역 유효 — MLP 직선화와 정반대

대가: 유닛 밖 함수 표현 불가 · 희소화 · 고차원 취약


함수 모양을 안다 (b) — NALU: 산술만 하도록 묶기



논문: Trask et al., NALU (NeurIPS 2018), Fig.2 (a) NAC · (b) NALU · arXiv:1808.00508

Fig.2 — (a) NAC · (b) NALU

- (a) NAC — +/- 부품
- $W = \tanh(\hat{W}) \odot \sigma(M) \rightarrow w \approx +1, 0, -1$
- $y = W \cdot x$ (matmul) · $w=+1$ 더함 · $w=-1$ 뺄셈
- (b) NALU — NAC + x + 스위치
- 가운데: NAC · 보라: $\log \rightarrow \text{matmul} \rightarrow \exp$ ($\times \div$)
- $g = \sigma \rightarrow y = g \cdot (\text{덧셈}) + (1-g) \cdot (\text{곱셈})$
- (a)는 부품 · (b)는 +단·x단 완성




예시 — 덧셈 학습

- 0~10으로 $a+b$ 학습 → 10,000까지 테스트
- MLP 오차 3,100배 폭발 · NALU는 평탄
- 대가: $w \cdot g \pm 1$ 수렴 보장 ❌ · 게이트 불안정
- 타깃이 산술 아니면 MLP로 붕괴 · $y=a+b$ 알면 코드가 나옴

가중치를 산술로 묶기 → 작은 수 훈련, 큰 수 일반화

방법 1 요약: 함수 모양 가정 = 최대 수익 · 최대 리스크

방향만 안다 (a) — 단조를 강제하면 표현력이 죽는다



논문: Runje & Shankaranarayana, Constrained Monotonic Neural Networks (ICML 2023), Fig.1 · arXiv:2205.11775

Fig.1 — $y = x^3$ (단조 증가 함수)

- (a) 무제약 NN: 적합은 되나 단조 보장 없음
- (b) 가중치 전부 양수: 단조는 되나 사실상 직선 — x^3 실패
- (c) CMNN: 단조 + 비선형 동시 (다음 장)
- 실무: 보험료↑·전압↑·수요↓ — 방향은 아는데 수식은 모를 때


단조(monotonic) 가정

- 입력↑ → 출력이 절대 안 줄어듦
- (또는 반대 방향)
- 실무 지식 대부분이 이 수준
-
- 딜레마
- 순진한 강제(가중치 자르기)는
- 표현력을 죽인다 — (b)
- 단조 vs 표현력, 둘 다?
- → 다음 장 CMNN

가중치 자르기: 단조는 얻지만 x^3 조차 실패 — 표현력 붕괴

단조 vs 표현력의 상충 — 해법은 다음 장

방향만 안다 (b) — 해법: 구조 자체가 단조이게 만들기 (CMNN)



논문: Runje & Shankaranarayana, Constrained Monotonic Neural Networks (ICML 2023), Fig.3

실무 예시 — 배터리 제어기

- 충전량(SOC) → 전압(OCV) 곡선을 CMNN으로 학습
- 훈련에 없던 고충전 조건 예측에도 '전압 급락'은 구조상 불가
- → 이 보장 하나로 제어기 안전 인증이 가능해진다

Fig.3 — 한 층 흐름

- $x \rightarrow |W|_t \cdot x + b \rightarrow \text{split}(s) \rightarrow \text{concat} \rightarrow W_{\text{out}} \rightarrow \hat{y}$
- t : 입력 feature마다 단조 방향 (+1 / -1 / 0)
- +1 → x_j ↑일 때 출력↑ (예: SOC↑ → OCV↑)
- -1 → x_j ↑일 때 출력↓
- 0 → 그 feature는 단조 제약 없음
- $|W|_t$: $t=\pm 1$ 일 때 w 부호만 고정 (전체 $|w|$ 아님)



s — 활성화 배치 (곡선 모양)

- $s = (\text{볼록 } \tilde{\rho}, \text{오목 } \hat{\rho}, \text{포화 } \tilde{\rho})$ — 합 = hidden m
- $\tilde{\rho}$: $h > 0$ 구간에서 증가 (ReLU 계열)
- $\hat{\rho}$: $h < 0$ 구간에서 증가 (거울 ReLU 계열)
- $\tilde{\rho}$: 위·아래 평평 (x^3 ·배터리는 보통 0)
- 예 $m=10, s=(4,4,0) \rightarrow \tilde{\rho}$ 4개 + $\hat{\rho}$ 4개
- 뉴런 번호로 ϕ 고정 — x 가 +/- 나로 바뀌지 않음

② CMNN — t=방향 · s=곡선 · 외삽=방향만 (구조)

값·모양은 자유 → ③ PDE(PINN)은 다음 장 · CMNN=구조 vs PINN=손실

물리 법칙을 안다 (a) — PINN: 물리를 손실에 넣기



③ PINN — ② CMNN 다음 단계

- ② CMNN: 방향만 **구조**로 (t, s)
- ③ PINN: **전체 PDE**를 **손실**로 (soft)
- $L = L_{data} + \lambda \cdot L_{PDE} + \lambda_b \cdot L_{BC/IC}$
- L_{data} : 관측 맞추기
- L_{PDE} : 잔차 $F[u] \approx 0$ (collocation)
- $L_{BC/IC}$: t=0·경계 (아래)
- 왼쪽 그림 = 2항 축소

실무 예시 — 자유낙하 궤적

- 관측: 낙하 초반 3개 지점뿐 (카메라 프레임 누락)
- 물리 항: $F = ma$, 즉 위치의 2차 미분 = $-g$ 를 여기에 벌점
- → 관측 없는 구간에서도 해가 포물선을 벗어나지 못한다
- 데이터 3점 + 물리 법칙 = 전체 궤적 복원 — 이게 PINN의 약속


BC/IC — 뭐고 언제?

- IC: t=0 시작 상태 (예: $u(x,0)=...$)
- BC: 공간 가장자리 (예: $u(0,t)=0$)
- PDE만으론 해 무한 → IC/BC로 하나 고정
- Burgers·NS field 복원: 보통 3항 전부
- 자유낙하: 초기값이 data에 있으면 2항만
- → soft — 시간 밖 보증? (다음 장)


③ PINN — CMNN(구조·방향)보다 강한 가정을 손실로

soft · 시간 밖? → 다음 장 Fessler · 검증은 그 뒤

물리 법칙을 안다 (b) — 반전: 물리를 넣어도 시간 외삽은 실패



논문: Fesser et al., Understanding and Mitigating Extrapolation Failures in PINNs (2023), Fig.1 · arXiv:2306.09478



실험 (위: 논문 원본)

- 시간 전반부로 학습 · 후반부로 평가
- → 오차 폭발 (Burgers-Allen-Cahn)
- 충격: 훈련 잔차는 '작았다'
- 원인: 잔차는 본 지점에서만 작고,
- 빠르게 변하는 성분은 덜 배운다



★ 3부 교훈 — 앞 PINN 장의 반전

- 앞 장: PDE+BC/IC 넣어도 soft
- → 시간 밖 보증 없다고 했음
- 여기: train $t \in [0, T/2]$, test 후반
- → 오차 폭발 · 잔차는 작았음
- 올바른 가정 ≠ 자동 보증
- → 검증 파트(S27~) 직접 동기

PINN(앞 장) 기대 ↔ Fesser(여기) 반전 — 잔차↓ ≠ 시간 밖 OK

CMNN·PINN 공통: 가정 넣어도 검증 별도 → S27~

사전 지식 없음 (a) — 불확실성 정량화 (UQ)



구조

- 불확실성 = 잡음 + 모름
- 잡음(aleatoric): 어디서나 일정
- 모름(epistemic): 훈련 범위 밖에서 급증
- ← 2부 이유 3의 그 항
- 그림: 밖으로 갈수록 띠가 벌어짐

가장 쉬운 구현 — 앙상블 5개

- 같은 데이터로 초기값만 다른 모델 5개를 학습
- 훈련 범위 안 입력: 5모델 답 비슷 → 믿어도 됨
- 훈련 범위 밖 입력: 5모델 답 제각각 → 외삽 경보


신호로 활용

- 약점을 감지기로:
- 모름 급증 = 외삽 경보
- 예측값보다 불확실성이 더 정보

모름(epistemic) 급증 = 외삽 영역 — 약점을 감지기로 활용

모를 때의 답: 예측값보다 불확실성이 정보다

사전 지식 없음 (b) — 자신 없으면 예측 안 함 (Zhu 2022)



논문: Zhu et al., Reliable Extrapolation of Deep Neural Operators (CMAME 2023), Fig.1 · arXiv:2212.06347

실무 예시 — 신소재 물성 예측

- 범위 밖 합금 조성 예측 → 신뢰도 $0.3 < 0.7$ → '실험 먼저'
- 오답 한 번(불량 배치)의 비용 $\gg$ 기권 한 번(실험 1회)의 비용

구조 (왼쪽 그림)

- 예측마다 신뢰도 점수를 매긴다
- (물리 잔차·관측과의 어긋남 활용)
- 임계값 미달 → 예측 대신 '안 함'(기권)
- 성능 지표가 바뀐다:
- 정확도 $\times$ 답변율(coverage)



왜 필요한가

- 모델은 밖에서도 자신 있게 답한다
- → 과신한 오답 전에 예측을 유보
- 고위험 분야의 최소 안전장치

신뢰 낮으면 예측 안 함(기권) — 과신 오답 방지

고위험 분야: 예측 안 함이 오답보다 싸다

같은 훈련 데이터 — 가정이 다르면 밖 거동이 전부 다르다




패널 = 넣은 가정

- 훈련점은 6패널 동일
- MLP: '밖=직선' (암묵)
- EQL: '달린 수식'
- Mono: '단조 방향'
- PINN: 'PDE 준수'
- UQ: '점추정 포기'
- → 데이터는 동일,
- 밖 거동만 다름
- 차이의 원인 = 가정
- (S03 정의의 시각화)

같은 데이터, 다른 가정 → 완전히 다른 밖 거동
차이는 데이터가 아니라 전부 가정에서 온다

선택 가이드 — 무엇을 아는가 → 그만큼의 가정 → 나머지는 UQ



가용 지식	방법	이득	대가
함수 모양·산술	EQL / NALU	전 영역 닫힌 식	가정이 틀릴 때 전역 실패·불안정
방향(단조)	CMNN	방향 역전 차단	구조 설계 비용
물리 법칙	PINN	물리 유도	잔차 ≠ 보증 (검증 필요)
없음	UQ + 기권	예측 안 함	답변을 감소


규칙

- 지식 우선
- 방법 후행
- 불확실하면 예측 안 함

지식 우선, 방법 후행, 불확실하면 예측 안 함(UQ)

남은 숙제: 가정이 '작동하는지' 어떻게 아는가 → 검증 4장

왜 외삽 성능 검증이 별도인가 — 밖에서도 모델은 확신한다



왜 가정이 있어도 검증이 필요한가


- 가정 주입(3부 방법) ≠ 자동 보증
- PINN: 참인 물리도 잔차만으로는
- 시간 외삽 실패 (Fessler 2023)
- 평가 설계가 틀리면 '외삽 성능'
- 숫자가 보간 점수가 됨
- → 가정 + 프로토콜이 한 세트

세 가지 함정 (장표만으로도 판정 가능해야 함)

- 함정 1 — 테스트가 훈련 범위 안만인가: '외삽 성능' 숫자가 실은 보간 점수
- 함정 2 — 높은 확신 + 낮은 정확도: 모델은 밖에서도 softmax/분산을 낮추지 않음 (그림 c)
- 함정 3 — 내부 지표 착시: 훈련 잔차·훈련 RMSE가 좋아도 밖 성능과 무관할 수 있음

테스트가 범위 안이면 외삽 점수는 오인 · 모델은 밖에서도 높은 확신
그래서 검증 절차가 따로 필요하다

'밖' 종류 분류 — OoD-Bench



두 축의 정의 (Ye et al., CVPR 2022)

- D_{div} : 훈련에 없던 영역·스타일 등장
- D_{cor} : 영역은 같고 입력-출력 규칙 변경
- '분포 밖(OOD)' 한 단어로 섞으면
- 방법 선택 근거 없음


실험적 함의

- 대부분 OOD 알고리즘은 두 축 중 한쪽에만 ERM 대비 우위
- 자기 데이터의 (D_{div} , D_{cor}) 프로파일을 재기 전에
- 방법을 고르면 약 절반은 효과가 없을 수 있음

'밖'을 두 축(diversity / correlation)으로 수치화 — 축을 모르면 방법 선택에 근거가 없다

대부분 알고리즘은 한 축에서만 효과

방법 비교 공정성 — DomainBed (ERM baseline)



그래프 읽는 법

- 점선 = 기본 학습(ERM) 66.6% — 전용 OOD 알고리즘 7종과 비교
- IRM 65.4·DANN 65.6: '전용' 알고리즘이 기본보다 오히려 나쁘다
- 최고 CORAL도 +0.9%p — 수년치 연구 차이가 튜닝 오차 수준

발견 (Gulrajani 2020)

- 14개 알고리즘 · 7개 데이터셋을
- 같은 튜닝 예산·같은 용량으로 재실험
- → 기본 학습(ERM)이 대부분 동급 이상
- 기존 '향상'의 상당수 = 튜닝 차이

가져갈 규칙

- ① ERM 기준선 필수
- ② 같은 튜닝 예산 · 같은 용량
- ③ 검증 전략 명시

공정하게 비교하면 ERM이 대부분 동급 이상 — 향상의 상당수는 튜닝에 의한 오인

ERM 기준선 · 같은 예산 · 같은 용량 · 검증 전략 명시

외삽 성능 주장 전 — 체크 4개



① 진짜 밖인가? (Bartley)

- test $\cap$ Conv(X_{train}) = $\emptyset$ 인가
- (= 테스트가 훈련 범위와 겹치지 않는가)
- 아니면 '보간 성능'으로 보고
- 변수별 min-max만으로 판정 금지

② 어떤 밖인가? (Ye 2022)

- D_{div} vs D_{cor} 축 프로파일 기록
- 축을 모른 채 방법만 바꾸지 말 것

③ 공정한가? (DomainBed)

- ERM 기준선 · 같은 튜닝 예산 · 모델 크기 · 검증 전략

④ 튼튼한가?

- 분할·시드·가정 약화에도 핵심 주장 유지? — 4문항 전 'SOTA' 자제

외삽 정의 · 실패 원인 · 대응법 · 성능 검증

1. 외삽 정의

- 외삽 = 새 입력이 훈련 범위 밖
- 모델 문제 X · 입력이 범위 밖 $\circ$
- 고차원에서는 밖이 기본값
- 가정 = 밖 거동에 대한
- 사전 제약·구조적 지식
- (같은 데이터, 다른 가정
- → 다른 외삽)

2. 실패 원인 (4)

- ① 함수 못 고름 (Pfister 2024)
- ② 고차원·대부분 밖 (Bartley)
- ③ 범위 밖에선 모름
- ④ ReLU → 멀리서 직선
- (Xu Thm.1, ICLR 2021)
- → '외삽 되나?'가 아니라
- '가정이 문제에 맞나?'

3. 대응법 + 성능 검증

- 대응 ①②: EQL · NALU / CMNN
- 대응 ③: PINN (잔차≠보증)
- 대응 ④: UQ · 기권(예측 안 함)
- 검증: 훈련 범위 · OoD-Bench
- · DomainBed · 민감도
- 지식 → 대응법 → 검증

밖을 지탱하는 것은 데이터가 아니라 가정이다

가정 = 훈련에 없는 영역의 함수 거동을 미리 제약하는 지식 · 올바르게 넣고 · 프로토콜로 검증한다

밖을 지탱하는 것은 데이터가 아니라 가정이다

외삽 정의 → 실패 원인 4 → 대응법 + 성능 검증

딱 3편만 남긴다면 — 진단 · 처방 · 검증

진단 — Xu et al. 2021 (ICLR)

- How NNs Extrapolate
- 신경망의 숨은 가정을 증명
- 2부의 근거

[PDF 열기](#)

처방 — Runje et al. 2023 (ICML)

- Constrained Monotonic NN
- 가정을 구조에 내장하는 설계
- 3부의 근거

[PDF 열기](#)

검증 — Gulrajani et al. 2020

- In Search of Lost DG
- 공정 비교의 규율
- 검증 파트의 근거

[PDF 열기](#)

더 읽기

Defactor 2024 (하스 문 전하), Fomberg 2022 (DMM 바레), Zhu 2022 (에츠 안 하), Ye 2022 (QoD Bench) — 전체 39편은 [paper_pdfs/+ INDEX.md](#)

Xu(진단) · Runje(처방) · DomainBed(검증)

전체 39편: [paper_pdfs/+ INDEX.md](#)

주황 버튼 → PDF · 전체는 paper_pdfs/ (39편) + INDEX.md

PDF

Xu 2021 — NN Extrapolate (2부·3부)

PDF

Pfister 2024 — 함수 못 정함 (2부)

PDF

Bartley 2019 — 고차원·훈련 범위 (1부·2부)

PDF

Martius 2016 — EQL (3부)

PDF

Trask 2018 — NALU (3부)

PDF

Runje 2023 — CMNN (3부)

PDF

Raissi 2019 — PINN (3부)

PDF

Fesser 2023 — PINN 반례 (3부)

PDF

Zhu 2022 — 예측 안 함·DeepONet (3부)

PDF

Ye 2022 — OoD-Bench (검증)

PDF

Gulrajani 2020 — DomainBed (검증)

PDF

학습노트 PDF (전체 정리)